

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería — Ciencias de la Computación

PROYECTO FINAL
CC3045 — Inteligencia Artificial

Diseño de un Sistema Inteligente Híbrido para la Planificación Académica Universitaria bajo Restricciones e Incertidumbre

*Integración de aprendizaje supervisado, CSP,
redes bayesianas y MDP para apoyo a la toma
de decisiones académicas*

Autores: [Pablo Daniel Barillas Moreno, Hugo Daniel Barillas Ajín y Roberto Nájera]
Carné(s): [22193, 23556 y 23781]
Docente: [Ing. Suriano]
Fecha: 25 de mayo de 2026
Semestre: I — 2026

Proyecto Final

Índice general

Resumen	4
1. Introducción	5
1.1. Motivación y contexto	5
1.2. Objetivos	5
1.3. Estructura del documento	6
2. Descripción del Problema	7
2.1. El proceso real de planificación académica	7
2.2. Entradas y salidas del sistema	7
2.3. Restricciones del sistema	8
2.3.1. Restricciones duras	8
2.3.2. Restricciones blandas	8
2.4. Complejidad del problema	8
3. Análisis del Problema	9
3.1. Descomposición en subproblemas	9
3.2. El sistema como agente inteligente	9
3.3. Análisis de cada subproblema	10
3.3.1. Capa 1: Predicción como problema de aprendizaje	10
3.3.2. Capa 2: Asignación como CSP	10
3.3.3. Capa 3: Incertidumbre como inferencia probabilística	10
3.3.4. Capa 4: Reacción como decisión secuencial (MDP)	11
4. Propuesta de Solución	12
4.1. Arquitectura global del sistema híbrido	12
4.2. Justificación del enfoque híbrido	12
4.3. Flujo de decisión del sistema	13
5. Descripción de la Solución	14
5.1. Módulo 1: Predicción de Demanda (ML)	14
5.1.1. Formulación del problema	14
5.1.2. Ingeniería de features	14
5.1.3. Modelos comparados	14
5.1.4. Pseudocódigo del módulo de predicción	15
5.1.5. Métricas de evaluación del módulo ML	15
5.2. Módulo 2: Generación de Horarios con CSP	15
5.2.1. Formulación formal	15
5.2.2. Factor graph y función objetivo	16
5.2.3. Grafo de restricciones	16
5.2.4. Heurísticas de búsqueda	16

5.3. Módulo 3: Evaluación de Riesgo con Redes Bayesianas	18
5.3.1. Motivación	18
5.3.2. Estructura de la red bayesiana	18
5.3.3. Inferencia probabilística	18
5.4. Módulo 4: Replanificación con MDP	19
5.4.1. Formulación del MDP	19
5.4.2. Ecuación de Bellman	19
5.4.3. Diagrama de transición de estados	20
5.5. Integración de módulos	20
5.5.1. Pipeline completo de decisión	20
5.5.2. Función objetivo global	21
6. Herramientas Aplicadas	22
6.1. Stack tecnológico	22
6.2. Uso de IA Generativa	22
6.2.1. Prompts utilizados	22
6.2.2. Evolución de la idea	23
6.2.3. Delimitación entre asistencia IA e implementación propia	23
6.3. Repositorio y entregables complementarios	24
7. Resultados y Métricas	25
7.1. Metodología experimental	25
7.2. Métricas por módulo	26
7.3. Instancias de prueba	26
7.4. Comparación de modelos ML	27
7.5. Comparación de estrategias de búsqueda CSP	27
7.6. Ablation study	28
8. Conclusiones	29
8.1. Conclusiones	29
8.2. Limitaciones	29
Bibliografía	30

Resumen

Este documento presenta el diseño, la arquitectura y la metodología de implementación de un **sistema inteligente híbrido** para la planificación académica universitaria. El sistema integra cuatro módulos de Inteligencia Artificial: (1) aprendizaje supervisado para la *predicción de demanda* de cursos; (2) Problemas de Satisfacción de Restricciones (CSP) con heurísticas para la *generación de horarios válidos*; (3) redes bayesianas para el *razonamiento probabilístico* y la estimación de riesgo; y (4) Procesos de Decisión de Markov (MDP) para la *replanificación adaptativa* ante contingencias.

La planificación académica en instituciones universitarias es un problema combinatorio NP-difícil que involucra múltiples capas de decisión, incertidumbre operativa y restricciones de diversa naturaleza. Los enfoques tradicionales tratan estos problemas de manera aislada; este proyecto propone una arquitectura cohesiva donde la salida de cada módulo alimenta al siguiente, logrando un sistema de decisión integral.

Palabras clave: CSP, scheduling académico, redes bayesianas, MDP, aprendizaje supervisado, heurísticas de búsqueda, sistema híbrido.

Capítulo 1

Introducción

1.1 Motivación y contexto

La planificación académica semestral es una de las tareas más críticas y complejas en la administración universitaria. En una institución de mediano tamaño, el proceso involucra coordinar cientos de cursos, decenas de docentes con disponibilidades heterogéneas, aulas con capacidades y equipamiento diverso, y restricciones curriculares que deben respetarse para garantizar la progresión académica de miles de estudiantes. Realizarlo manualmente es costoso en tiempo, propenso a errores y casi siempre subóptimo.

Desde la perspectiva de la Inteligencia Artificial, este problema trasciende la simple generación de horarios. En realidad se trata de un **problema de decisión multicapa**: es necesario *predecir* cuántas secciones abrir, *asignar* recursos bajo restricciones, *estimar* el riesgo de conflictos futuros y *reaccionar* de forma inteligente cuando los planes originales deben modificarse.

Este proyecto demuestra que las técnicas de IA vistas en el curso — agentes inteligentes, búsqueda heurística, CSP, razonamiento probabilístico, aprendizaje supervisado y MDP — no son herramientas aisladas sino componentes complementarios de un sistema de decisión real e integrado.

1.2 Objetivos

Objetivo general

Diseñar e implementar un sistema inteligente híbrido para la planificación académica universitaria que integre predicción de demanda, generación de horarios bajo restricciones, razonamiento probabilístico y replanificación adaptativa.

Objetivos específicos

1. Construir un módulo de predicción de demanda usando aprendizaje supervisado y comparar al menos tres algoritmos.
2. Modelar la generación de horarios como CSP e implementar backtracking con forward checking, MRV y LCV.
3. Diseñar una red bayesiana para estimar la probabilidad de conflictos académicos bajo incertidumbre.

4. Formalizar un MDP simplificado para la replanificación adaptativa y derivar una política de acción.
5. Integrar los cuatro módulos en un pipeline unificado y evaluarlo sobre instancias sintéticas.

1.3 Estructura del documento

El capítulo 2 describe el problema y sus complejidades. El capítulo 3 lo analiza desde múltiples perspectivas de IA. El capítulo 4 presenta la propuesta global. El capítulo 5 detalla cada módulo. El capítulo 6 documenta las herramientas. El capítulo 7 presenta metodología experimental. El capítulo 8 cierra con conclusiones y trabajo futuro.

Capítulo 2

Descripción del Problema

2.1 El proceso real de planificación académica

La planificación académica semestral en una universidad comprende las siguientes actividades interrelacionadas:

1. **Estimación de demanda:** decidir cuántas secciones de cada curso deben abrirse, basado en proyecciones de inscripción y capacidad docente.
2. **Asignación de recursos:** asignar a cada sección una franja horaria, un aula y un docente, respetando todas las restricciones administrativas y académicas.
3. **Gestión de contingencias:** gestionar cambios de último momento (ausencias, sobrecupo, averías) de forma rápida y coherente.
4. **Comunicación y publicación:** distribuir el horario final a estudiantes, docentes y administración.

2.2 Entradas y salidas del sistema

Cuadro 2.1: Entradas y salidas del sistema de planificación académica.

Tipo	Entidad	Descripción
Entrada	Cursos	Nombre, créditos, prerrequisitos, carrera
Entrada	Estudiantes	Número proyectado, historial de inscripción
Entrada	Docentes	Disponibilidades, cursos habilitados, carga máxima
Entrada	Aulas	Capacidad, equipamiento, disponibilidad
Entrada	Histórico	Inscripciones pasadas, tasas de aprobación, demanda
Entrada	Restricciones	Reglas duras y blandas administrativas
Salida	Predicción	Número esperado de secciones por curso
Salida	Horario	Asignación completa sección→(franja, aula, docente)
Salida	Evaluación	Métricas de calidad, riesgo de conflicto estimado
Salida	Replanificación	Acciones sugeridas ante contingencias

2.3 Restricciones del sistema

2.3.1 Restricciones duras

- Un docente no puede impartir dos secciones en la misma franja horaria.
- Un aula no puede albergar dos secciones simultáneamente.
- La capacidad del aula debe ser mayor o igual al cupo de la sección.
- Un docente solo puede impartir cursos para los que está habilitado.
- Un docente solo puede asignarse en franjas de su disponibilidad declarada.

2.3.2 Restricciones blandas

- Minimizar los intervalos libres en el horario de cada docente.
- Respetar las preferencias de franja horaria de los docentes.
- Distribuir la carga docente equitativamente entre los días de la semana.
- Concentrar los cursos de un mismo pensum en bloques contiguos.
- Evitar asignar cursos de alta demanda en las primeras o últimas franjas.

2.4 Complejidad del problema

Sea n el número de secciones, t el número de franjas, r el número de aulas y p el número de docentes disponibles. El espacio de búsqueda ingenuo tiene cardinalidad:

$$|\mathcal{S}| = (t \cdot r \cdot p)^n \quad (2.1)$$

Para una facultad con $n = 80$, $t = 25$, $r = 15$, $p = 20$: $|\mathcal{S}| = 7500^{80} \approx 10^{310}$. Esto demuestra que la búsqueda ingenua es completamente inviable y justifica la necesidad de métodos inteligentes.

Capítulo 3

Análisis del Problema

3.1 Descomposición en subproblemas

El problema global se descompone en cuatro subproblemas con distintas características computacionales:

Cuadro 3.1: Descomposición del problema y técnica de IA aplicada.

Capa	Subproblema	Técnica de IA	Paradigma
1	Predicción de demanda	Aprendizaje supervisado	ML
2	Generación de horarios	CSP + heurísticas	Búsqueda
3	Estimación de riesgo	Redes bayesianas	Razonamiento probabil.
4	Replanificación	MDP	Decisión secuencial

3.2 El sistema como agente inteligente

Siguiendo el paradigma de agentes inteligentes de Russell y Norvig Russell y Norvig, 2021, el sistema puede modelarse como:

Definición

Un agente de planificación académica es una función $f : \mathcal{P}^* \rightarrow \mathcal{A}$ que mapea secuencias de percepciones a acciones, donde:

- $\mathcal{P}$ = percepciones: inscripciones históricas, disponibilidades, contingencias.
- $\mathcal{A}$ = acciones: asignar sección, mover franja, cancelar sección, reasignar docente.
- El objetivo es maximizar la métrica de calidad global: $Q = \eta_H \cdot \eta_S \cdot (1 - P_{\text{riesgo}})$.




Figura 3.1: Modelo del sistema como agente inteligente en su entorno académico.

3.3 Análisis de cada subproblema

3.3.1 Capa 1: Predicción como problema de aprendizaje

La predicción de demanda es una tarea de **regresión o clasificación**: dado un vector de características históricas $\mathbf{x}_i$ de un curso, predecir la demanda esperada $\hat{y}_i$. Sea $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ el conjunto de entrenamiento. El objetivo es encontrar una función $h : \mathbb{R}^d \rightarrow \mathbb{R}$ que minimice la función de pérdida:

$$h^* = \arg \min_{h \in \mathcal{H}} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(h(\mathbf{x}_i), y_i) + \lambda \Omega(h) \quad (3.1)$$

donde $\mathcal{L}$ es la función de pérdida (MSE para regresión, entropía cruzada para clasificación) y $\Omega(h)$ es un término de regularización.

3.3.2 Capa 2: Asignación como CSP

Definición 3.1. Un CSP se define como $\langle X, D, C \rangle$ donde: $X = \{X_1, \dots, X_n\}$ son las variables (secciones), $D = \{D_1, \dots, D_n\}$ son los dominios, y C es el conjunto de restricciones.

El espacio de estados tiene cardinalidad dada por la ecuación (2.1). Las heurísticas MRV y LCV, junto con forward checking, reducen este espacio en varios órdenes de magnitud.

3.3.3 Capa 3: Incertidumbre como inferencia probabilística

Los eventos inciertos (ausencia de docente, sobrecupo) se modelan mediante una red bayesiana con variables latentes. El teorema de Bayes:

$$P(Q \mid E = e) = \frac{P(E = e \mid Q) P(Q)}{P(E = e)} \quad (3.2)$$

permite actualizar las probabilidades de riesgo dado nueva evidencia.

3.3.4 Capa 4: Reacción como decisión secuencial (MDP)

El proceso de replanificación se modela como un MDP $\langle S, A, T, R, \gamma \rangle$ donde los estados representan configuraciones del horario y las acciones corresponden a modificaciones posibles. La ecuación de Bellman:

$$V^*(s) = \max_{a \in A} \left[R(s, a) + \gamma \sum_{s' \in S} T(s, a, s') V^*(s') \right] \quad (3.3)$$

permite derivar la política óptima $\pi^*(s) = \arg \max_a Q^*(s, a)$.

Capítulo 4

Propuesta de Solución

4.1 Arquitectura global del sistema híbrido




Figura 4.1: Arquitectura global del sistema inteligente híbrido.

4.2 Justificación del enfoque híbrido

Cuadro 4.1: Comparación entre enfoque único y sistema híbrido propuesto.

Criterio	Enfoque único (solo CSP)	Sistema híbrido propuesto
Predicción	No considera demanda futura	ML predice secciones necesarias
Asignación	Genera horario bajo restricciones	CSP genera horario óptimo con dominio reducido por ML
Incertidumbre	Supone datos perfectos	Bayes modela eventos inciertos y estima riesgo
Adaptabilidad	Estático ante cambios	MDP decide acción óptima en contingencias
Cobertura del curso	Una sola técnica	ML + CSP + Bayes + MDP (4 módulos)
Aplicabilidad real	Limitada	Alta

4.3 Flujo de decisión del sistema

El sistema opera secuencialmente en cuatro fases:

1. **Fase 1 — Predicción:** el módulo ML analiza el histórico y genera una predicción de demanda por curso, determinando cuántas secciones deben abrirse.
2. **Fase 2 — Generación:** con las secciones definidas, el módulo CSP construye el horario válido aplicando backtracking con MRV, LCV y forward checking.
3. **Fase 3 — Evaluación de riesgo:** la red bayesiana analiza el horario generado y estima la probabilidad de cada tipo de conflicto ($P(\text{conflicto} \mid \text{horario})$).
4. **Fase 4 — Replanificación:** si el riesgo supera un umbral θ , o si ocurre una contingencia real, el módulo MDP selecciona la acción óptima de reajuste.

Capítulo 5

Descripción de la Solución

5.1 Módulo 1: Predicción de Demanda (ML)

5.1.1 Formulación del problema

La predicción de demanda se formula como un problema de **regresión** donde la variable objetivo es y_i = número de estudiantes esperados en el curso i para el siguiente semestre. Como problema de clasificación, puede binarizarse: $y_i = 1$ si se proyecta sobrecupo, 0 en caso contrario.

5.1.2 Ingeniería de features

Cuadro 5.1: Variables (features) para el módulo de predicción.

Feature	Tipo	Descripción
x_1 : demanda_hist	numérica	Inscripciones promedio últimos 3 semestres
x_2 : tasa_aprobacion	numérica	Fracción de aprobados histtóricamente
x_3 : semestre	categorica	Primer o segundo semestre del año
x_4 : tiene_prereq	binaria	Si el curso tiene prerrequisito
x_5 : capacidad_prev	numérica	Cupo asignado en el semestre anterior
x_6 : turno	categorica	Mañana / tarde / noche
x_7 : carrera	categorica	Carrera a la que pertenece el curso
x_8 : n_secciones_prev	numérica	Número de secciones abiertas anteriormente
x_9 : tendencia	numérica	Pendiente de la demanda en los últimos 4 semestres

5.1.3 Modelos comparados

Se comparan los siguientes modelos de aprendizaje supervisado:

- **Regresión lineal**: $\hat{y} = \mathbf{w}^\top \mathbf{x} + b$
- **Regresión logística** (versión clasificación): $P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$
- **Árbol de decisión**: particiones recursivas del espacio de features
- **Naive Bayes**: $\hat{y} = \arg \max_k P(y = k) \prod_j P(x_j|y = k)$
- **SVM**: $\hat{y} = \text{sign}(\mathbf{w}^\top \phi(\mathbf{x}) + b)$

5.1.4 Pseudocódigo del módulo de predicción

Algorithm 1 Entrenamiento y evaluación del módulo de predicción

Entrada: Conjunto de datos histórico $\mathcal{D}$, lista de modelos $\mathcal{M}$

Salida: Mejor modelo h^* y predicciones $\hat{Y}$

```

1:  $\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{test}} \leftarrow \text{SplitStratified}(\mathcal{D}, 0.8)$ 
2: Preprocesar: imputar, normalizar, codificar categóricas
3: Seleccionar features con correlación o importancia  $>$  umbral
4: para cada  $m \in \mathcal{M}$  hacer
5:    $h_m \leftarrow \text{Entrenar}(m, \mathcal{D}_{\text{train}})$  con validación cruzada 5-fold
6:    $\text{score}_m \leftarrow \text{Evaluar}(h_m, \mathcal{D}_{\text{test}})$ 
7: end for
8:  $h^* \leftarrow \arg \max_m \text{score}_m$ 
9:  $\hat{Y} \leftarrow h^*(\mathbf{X}_{\text{nuevo semestre}})$  return  $h^*, \hat{Y}$ 

```

5.1.5 Métricas de evaluación del módulo ML

Para regresión: $\text{MAE} = \frac{1}{N} \sum |y_i - \hat{y}_i|$, $\text{RMSE} = \sqrt{\frac{1}{N} \sum (y_i - \hat{y}_i)^2}$. Para clasificación: accuracy, precision, recall, F1-score y AUC-ROC. El criterio de selección de modelo es:

$$h^* = \arg \min_{m \in \mathcal{M}} \text{RMSE}_{\text{CV}}(m) + \lambda \cdot \text{Complejidad}(m) \quad (5.1)$$

5.2 Módulo 2: Generación de Horarios con CSP

5.2.1 Formulación formal

Definición 5.1. El CSP de scheduling académico es $\langle X, D, C \rangle$ donde:

- $X_i = (\text{franja}_i, \text{aula}_i, \text{docente}_i)$ para cada sección i .
- $D_i = T \times R_i \times P_i$ donde T es el conjunto de franjas, R_i las aulas con capacidad suficiente, y P_i los docentes habilitados.
- C incluye las restricciones de no solapamiento (ecuaciones 5.2–5.4).

$$\forall i \neq j : (\text{doc}_i = \text{doc}_j) \Rightarrow (\text{franja}_i \neq \text{franja}_j) \quad (5.2)$$

$$\forall i \neq j : (\text{aula}_i = \text{aula}_j) \Rightarrow (\text{franja}_i \neq \text{franja}_j) \quad (5.3)$$

$$\forall i : \text{cap}(\text{aula}_i) \geq \text{cupo}(i) \quad (5.4)$$

5.2.2 Factor graph y función objetivo

$$\text{Weight}(\mathbf{x}) = \prod_j f_j(\mathbf{x}_{\text{scope}(j)}), \quad f_j \in [0, 1] \quad (5.5)$$

$$\mathbf{x}^* = \arg \max_{\mathbf{x} \in \mathcal{F}} \text{Weight}(\mathbf{x}) \quad (5.6)$$

donde $\mathcal{F}$ es el conjunto de asignaciones que satisfacen todas las restricciones duras.

5.2.3 Grafo de restricciones




Figura 5.1: Grafo de restricciones entre secciones. Aristas sólidas = restricciones activas.

5.2.4 Heurísticas de búsqueda

MRV (Minimum Remaining Values):

$$X^* = \arg \min_{X_i \notin \text{asignadas}} |D_i^{\text{actual}}| \quad (5.7)$$

LCV (Least Constraining Value):

$$\text{lcv}(v, X_i) = \sum_{X_j \in N(X_i)} |\{d \in D_j : (v, d) \text{ viola } C\}| \quad (5.8)$$

Algorithm 2 Backtracking con FC, MRV y LCV

Entrada: CSP $\langle X, D, C \rangle$ **Salida:** Asignación completa o FALLO

```

1: function BACKTRACK( $A, D$ )
2:   if  $A$  completa then return  $A$ 
3:   end if
4:    $X_i \leftarrow \text{MRV}(A, D)$ 
5:   para cada  $v \in \text{LCV}(X_i, D, A)$  hacer
6:     if  $v$  consistente con  $A$  then
7:        $A \leftarrow A \cup \{X_i = v\}$ 
8:        $D' \leftarrow \text{ForwardChecking}(X_i, v, D)$ 
9:       if  $D' \neq \text{FALLO}$  then
10:        resultado  $\leftarrow \text{BACKTRACK}(A, D')$ 
11:        if resultado  $\neq \text{FALLO}$  then return resultado
12:        end if
13:      end if
14:       $A \leftarrow A \setminus \{X_i = v\}$ ; restaurar  $D$ 
15:    end if
16:  end for return FALLO
17: end function

```

Algorithm 3 Beam Search para generación de horarios

Entrada: Ancho k , CSP, función de evaluación Eval**Salida:** Mejor asignación encontrada

```

1: function BEAMSEARCH( $k, \text{CSP}$ )
2:   beam  $\leftarrow [\{\}]$ 
3:   while beam no vacío do
4:     candidatos  $\leftarrow []$ 
5:     para cada  $A \in \text{beam}$  hacer
6:        $X_i \leftarrow$  siguiente variable no asignada (MRV)
7:       para cada  $v \in D_i$  hacer
8:         if  $A \cup \{X_i = v\}$  consistente then candidatos.add( $A \cup \{X_i = v\}$ )
9:         end if
10:      end for
11:    end for
12:    if candidatos vacío then return mejor en beam
13:    end if
14:    beam  $\leftarrow$  top- $k$  de candidatos según Eval
15:  end while
16: end function

```

5.3 Módulo 3: Evaluación de Riesgo con Redes Bayesianas

5.3.1 Motivación

Una vez generado el horario base, existen eventos inciertos que podrían invalidarlo: ausencia inesperada de un docente, demanda mayor a la predicha, falla de equipo en un aula especializada. La red bayesiana permite cuantificar *a priori* la probabilidad de cada tipo de conflicto.

5.3.2 Estructura de la red bayesiana




Figura 5.2: Red bayesiana para estimación de riesgo académico.

5.3.3 Inferencia probabilística

La probabilidad de que se requiera replanificación dada la evidencia $E = e$:

$$P(\text{Replanif.} = 1 \mid E = e) = \frac{P(E = e \mid \text{Replanif.} = 1) P(\text{Replanif.} = 1)}{P(E = e)} \quad (5.9)$$

El algoritmo de inferencia exacta (eliminación de variables) calcula la distribución marginal de cualquier nodo dado un conjunto de nodos observados.

Algorithm 4 Evaluación de riesgo probabilístico

Entrada: Red bayesiana $\mathcal{B}$, horario H , umbral θ

Salida: Probabilidad de riesgo p_{risk} y bandera de alerta

- 1: Extraer evidencia e del horario H : disponibilidades, demanda predicha
 - 2: $p_{\text{risk}} \leftarrow P(\text{Replanif.} = 1 \mid e)$ (inferencia en $\mathcal{B}$)
 - 3: **if** $p_{\text{risk}} > \theta$ **then return** p_{risk} , ALERTA
 - 4: **elsereturn** p_{risk} , OK
 - 5: **end if**
-

5.4 Módulo 4: Replanificación con MDP

5.4.1 Formulación del MDP

Cuando ocurre una contingencia, el proceso de replanificación se formaliza como un MDP $\langle S, A, T, R, \gamma \rangle$:

Cuadro 5.2: Componentes del MDP de replanificación.

Componente	Descripción
S	Configuraciones del horario: (secciones asignadas, conflictos activos, recursos disponibles)
A	Acciones: mover franja, reasignar aula, cambiar docente, abrir nueva sección, mantener plan
$T(s, a, s')$	Probabilidad de transitar al estado s' al tomar acción a en estado s (derivada de la red bayesiana)
$R(s, a)$	Recompensa: +10 si se resuelve el conflicto sin afectar otros cursos; -5 si genera nuevos conflictos
γ	Factor de descuento $\gamma = 0.9$

5.4.2 Ecuación de Bellman

La función de valor óptima satisface:

$$V^*(s) = \max_{a \in A(s)} \left[R(s, a) + \gamma \sum_{s' \in S} T(s, a, s') V^*(s') \right] \quad (5.10)$$

La política óptima se extrae como:

$$\pi^*(s) = \arg \max_{a \in A(s)} \left[R(s, a) + \gamma \sum_{s' \in S} T(s, a, s') V^*(s') \right] \quad (5.11)$$

5.4.3 Diagrama de transición de estados




Figura 5.3: Diagrama simplificado de transición de estados en el MDP de replanificación.

Algorithm 5 Selección de acción en el MDP (política greedy)

Entrada: Estado actual s , función $Q^*(s, a)$, MDP

Salida: Acción óptima a^*

- 1: Observar estado del horario: conflictos, recursos, probabilidades de riesgo
 - 2: Actualizar $s \in S$ con el estado actual observado
 - 3: $a^* \leftarrow \arg \max_{a \in A(s)} Q^*(s, a)$
 - 4: Ejecutar a^* sobre el horario
 - 5: Observar nuevo estado s' y recompensa r
 - 6: Actualizar estimaciones si se usa aprendizaje por refuerzo **return** a^*, s'
-

5.5 Integración de módulos

5.5.1 Pipeline completo de decisión




Figura 5.4: Pipeline completo de decisión del sistema híbrido.

5.5.2 Función objetivo global

La calidad global del sistema se define como:

$$Q_{\text{global}} = \underbrace{\eta_H}_{\text{CSP duras}} \cdot \underbrace{\eta_S}_{\text{CSP blandas}} \cdot \underbrace{(1 - P_{\text{riesgo}})}_{\text{Bayes}} \cdot \underbrace{\frac{V^*(s_{\text{init}})}{V_{\text{máx}}}}_{\text{MDP}} \quad (5.12)$$

El sistema busca maximizar Q_{global} a través del pipeline de cuatro módulos.

Capítulo 6

Herramientas Aplicadas

6.1 Stack tecnológico

Cuadro 6.1: Herramientas y bibliotecas del proyecto.

Herramienta	Versión	Uso
Python	3.11	Lenguaje principal
Jupyter Notebook	7.x	Documentación ejecutable (.ipynb)
NumPy / Pandas	1.26 / 2.1	Manejo de datos y matrices
scikit-learn	1.4	Modelos ML, CV, métricas
pgmpy	0.1.x	Redes bayesianas e inferencia
Matplotlib / Seaborn	3.8	Visualización
constraint	1.4	Biblioteca CSP de referencia
Overleaf	—	Documentación LaTeX
Git / GitHub	—	Repositorio público y control de versiones

6.2 Uso de IA Generativa

Esta sección documenta, conforme a las instrucciones del curso, el uso de herramientas de IA generativa como apoyo al desarrollo del proyecto.

6.2.1 Prompts utilizados

1. Prompt de exploración del diseño híbrido:

“Necesito diseñar un sistema de planificación académica que use más de una técnica de IA. Qué combinación de métodos sería coherente y justificable? Quiero que se relacione con: aprendizaje supervisado, CSP, redes bayesianas y MDP.”

Por qué funcionó: el prompt especificó explícitamente las cuatro técnicas objetivo, lo que orientó la respuesta hacia integración real en lugar de descripción aislada de cada método.

2. Prompt de formalización del MDP:

“Dame un ejemplo concreto de cómo modelar la replanificación de horarios como un MDP: define estados, acciones, recompensas y la ecuación de Bellman aplicada.”

Por qué funcionó: solicitar un ejemplo concreto con los componentes formales obligó a la IA a producir definiciones precisas, verificables contra la bibliografía del curso.

3. Prompt de depuración del módulo CSP:

“Mi forward checking no está propagando correctamente cuando hay más de un docente elegible por sección. Revisa este código y explica el error conceptual.”

Por qué funcionó: proporcionar el código real permitió un diagnóstico preciso; la IA no inventó el problema.

6.2.2 Evolución de la idea

Iteración 1. Inicio con solo CSP. La IA ayudó a identificar que el problema era más rico e incluir predicción y riesgo.

Iteración 2. Incorporación del módulo ML para predicción de demanda; la IA sugirió el pipeline de datos y la selección de features.

Iteración 3. Diseño de la red bayesiana; la IA explicó la estructura de nodos; la topología final fue diseñada y validada por el equipo.

Iteración 4. Formalización del MDP; ecuaciones y pseudocódigo fueron desarrollados por el equipo con la IA como referencia.

6.2.3 Delimitación entre asistencia IA e implementación propia

Componente	Asistencia IA	Propio
Diseño del pipeline híbrido	Orientación	✓
Modelado formal CSP	Bibliografía	✓
Implementación backtracking + FC	Revisión	✓
Topología de la red bayesiana	Sugerencia	✓
Formalización MDP y Bellman	Referencia	✓
Features de predicción (ML)	Lista inicial	✓
Diseño de experimentos	Sugerencia	✓
Redacción académica	Apoyo estilo	✓

6.3 Repositorio y entregables complementarios

Todo el código fuente está disponible en un repositorio público:

Repositorio del proyecto final: [GitHub](#)

1. **Documento PDF** (este archivo).
2. **Notebook Jupyter** (.ipynb) con implementación y experimentos.
3. **Código fuente** organizado por módulos en el repositorio.
4. **Video explicativo** (≈ 7 min) con demostración del sistema.
5. **Presentación** (máx. 10 diapositivas) para la exposición.

Capítulo 7

Resultados y Métricas

7.1 Metodología experimental

La evaluación del sistema sigue un protocolo por módulo. El experimento utilizó el dataset **OULAD real** con $n = 11\,999$ observaciones (datos de la Open University, UK). Los modelos ML se evaluaron con un 25 % de datos de prueba ($n_{\text{test}} = 3\,000$). El CSP resolvió una instancia de **10 secciones** con 25 franjas, 7 aulas y 8 profesores. La red bayesiana y el MDP fueron evaluados sobre ese mismo horario generado.

1. **Módulo ML**: comparación de 5 modelos (Random Forest, Extra Trees, Regresión logística, SGD y baseline); tiempo total de entrenamiento: 0.71 s.
2. **Módulo CSP**: instancia Tiny ($n = 10$) resuelta con BT+FC+MRV+LCV; 0 retrocesos, $\eta_H = 1.0$.
3. **Módulo Bayes**: red bayesiana de 6 nodos; evaluada sobre las 10 secciones asignadas; Brier score = 0.117.
4. **Módulo MDP**: 5 estados, 5 acciones; política derivada con value iteration ($\gamma = 0.9$); $V^*(s_{\text{normal}}) = 140.0$.

KPIs globales del experimento real:

- Fuente de datos: OULAD real ($n = 11\,999$, modo rápido).
- Mejor modelo: **Random Forest** — $F1 = 0.934$, $AUC = 0.981$.
- Umbral de decisión óptimo: $\tau = 0.23$ (mínimo coste FP/FN).
- CSP: 10/10 secciones asignadas, **0 retrocesos**, tiempo < 0.01 s.
- Red bayesiana: riesgo medio $P(\text{Replanif}) = 0.719$; Brier = 0.117.
- MDP: $V^*(s_{\text{normal}}) = 140.0$; acción dominante: *open_extra*.
- Q_{global} sistema completo: **0.219**.

7.2 Métricas por módulo

Cuadro 7.1: Métricas de evaluación por módulo con resultados reales del experimento.

Módulo	Métrica	Definición	Objetivo	Resultado
ML	F1-score	$2 \cdot \frac{P \cdot R}{P + R}$	Maximizar	0.934
ML	AUC-ROC	Área bajo la curva ROC	Maximizar	0.981
ML	Accuracy	Fracción de predicciones correctas	Maximizar	0.933
ML	Umbral τ	Umbral de decisión óptimo (coste)	—	0.23
CSP	η_H	Fracción restricc. duras satisfechas	= 1.0	1.00
CSP	η_S	Calidad de restricc. blandas	Maximizar	1.00*
CSP	Backtracks	Núm. de retrocesos	Minimizar	0
CSP	T (s)	Tiempo de cómputo	Minimizar	< 0.01
Bayes	Log-lik.	$\sum \log P(e_i \mathcal{B})$	Maximizar	−27.16
Bayes	Brier score	$\frac{1}{N} \sum (p_i - o_i)^2$	Minimizar	0.117
Bayes	$P(\text{Replanif})$	Riesgo medio de replanificación	Referencia	0.719
MDP	$V^*(s_0)$	Valor del estado normal bajo π^*	Maximizar	140.0
MDP	Acción MRV	Acción más frecuente según política	—	<i>open_extra</i>
Global	Q_{global}	Ec. (5.12)	Maximizar	0.219

* Inferida: ninguna sección requirió retroceso; cada asignación obtuvo la primera opción de mayor puntaje.

7.3 Instancias de prueba

Cuadro 7.2: Instancias de prueba para el módulo CSP. La instancia *Tiny* corresponde a la ejecución real del notebook ($n_{\text{secc.}} = 10$, $t = 25$ franjas, $r = 7$ aulas, $p = 8$ profesores). Las instancias Small–Large son proyecciones no evaluadas en este experimento.

Inst.	n	t	r	p	η_H	η_S	Backtracks	$T(\text{s})$
Tiny	10	25	7	8	1.00	1.00*	0	< 0.01
Small	25	25	7	8	—	—	—	—
Medium	50	25	7	8	—	—	—	—
Large	100	25	7	8	—	—	—	—

* η_S inferida: sin retrocesos, toda sección asignada a su primera opción de mayor puntaje.

7.4 Comparación de modelos ML

Cuadro 7.3: Comparación de modelos para predicción de riesgo académico (dataset OU-LAD real, $n = 11\,999$ observaciones, conjunto de prueba 25 %). El mejor modelo por F1 se destaca en negrita.

Modelo	Accuracy	Precisión	Recall	F1	AUC
Random Forest	0.933	0.972	0.900	0.934	0.981
Extra Trees	0.929	0.967	0.895	0.930	0.974
Regresión logística	0.871	0.896	0.855	0.875	0.942
SGD (log-loss)	0.858	0.835	0.910	0.871	0.939
Dummy (baseline)	0.528	0.528	1.000	0.691	0.500

7.5 Comparación de estrategias de búsqueda CSP

BT+FC+MRV+LCV: resultado real (Tiny, $n=10$, backtracks=0); curvas Small–Large son proyecciones teóricas




Figura 7.1: Comparación ilustrativa de backtracks por estrategia de búsqueda.

7.6 Ablation study

Cuadro 7.4: Ablation study del sistema híbrido con valores calculados sobre el experimento real. $Q_{\text{global}} = \eta_H \cdot \eta_S \cdot (1 - P_{\text{riesgo}}) \cdot V^*(s_0)/V_{\text{máx}}$, donde los factores omitidos se fijan en 1. Datos: $\eta_H = 1.00$, $\eta_S = 1.00$, $P_{\text{riesgo}} = 0.719$, $V^*(s_{\text{normal}}) = 140.0$, $V_{\text{máx}} = 180.0$.

Configuración	ML	CSP	Bayes	MDP	Q_{global}
Solo CSP	×	✓	×	×	1.000
ML + CSP	✓	✓	×	×	1.000
ML + CSP + Bayes	✓	✓	✓	×	0.281
Sistema completo	✓	✓	✓	✓	0.219

Nota: La reducción al agregar Bayes refleja el riesgo real del horario ($P=0.719$); el MDP pondera además la cal

Capítulo 8

Conclusiones

8.1 Conclusiones

1. **Integración coherente de múltiples técnicas de IA.** El sistema híbrido demuestra que ML, CSP, redes bayesianas y MDP no son herramientas aisladas: cada una resuelve una capa específica del problema y sus salidas se encadenan de forma lógica en el pipeline de decisión.
2. **Desempeño comprobado del módulo ML.** El mejor modelo, Random Forest, alcanzó $F1 = 0.934$ y $AUC = 0.981$ sobre el dataset OULAD real ($n = 11\,999$), superando a todos los baselines. El umbral de decisión óptimo fue $\tau = 0.23$, obtenido minimizando el coste diferencial entre falsos positivos y falsos negativos.
3. **Efectividad del módulo CSP.** El solucionador BT+FC+MRV+LCV resolvió la instancia de 10 secciones con **0 retrocesos** y $\eta_H = 1.0$, generando un horario factible en tiempo despreciable. La red bayesiana reveló un riesgo operativo elevado ($P(\text{Replanif}) = 0.719$), lo que ilustra el valor de incorporar el módulo 3: el CSP en solitario no detecta esta vulnerabilidad.
4. **Aplicabilidad real.** El problema de planificación académica es un caso de uso real en cualquier universidad. Los módulos propuestos son implementables con bibliotecas abiertas de Python y datos históricos de inscripción.
5. **Cobertura de los temas del curso.** El proyecto integra explícitamente: agentes inteligentes, búsqueda heurística, CSP/factor graphs, beam search, redes bayesianas, aprendizaje supervisado y MDP, demostrando una comprensión transversal del curso de IA.

8.2 Limitaciones

- La red bayesiana requiere estimación manual de las tablas de probabilidad condicional en ausencia de datos históricos suficientes.
- El MDP simplificado asume un espacio de estados finito y discreto; la realidad puede ser más compleja.
- La escalabilidad del backtracking disminuye para instancias con $n > 150$ secciones sin optimizaciones adicionales.

Bibliografía

- Babaei, H., Karimpour, J., & Hadidi, A. (2015). A survey of approaches for university course timetabling problem. *Computers & Industrial Engineering*, 86, 43-59. <https://doi.org/10.1016/j.cie.2014.11.010>
- Chen, M. C., Sze, S. N., Goh, S. L., Sabar, N. R., & Kendall, G. (2021). A survey of university course timetabling problem: Perspectives, trends and opportunities. *IEEE Access*, 9, 106515-106529. <https://doi.org/10.1109/ACCESS.2021.3100613>
- Dechter, R. (2003). *Constraint Processing*. Morgan Kaufmann.
- Mackworth, A. K. (1977). Consistency in networks of relations. *Artificial Intelligence*, 8(1), 99-118. [https://doi.org/10.1016/0004-3702\(77\)90007-8](https://doi.org/10.1016/0004-3702(77)90007-8)
- Müller, T. (2005). *Constraint-based timetabling* [Tesis doctoral, Charles University in Prague, Faculty of Mathematics y Physics].
- Müller, T. (n.d.). *Tomáš Müller – UniTime*. Consultado el 13 de abril de 2026, desde <https://muller.unitime.org/>
- Rossi-Doria, O., Blum, C., Knowles, J., Sampels, M., Socha, K., & Paechter, B. (2002). A local search for the timetabling problem [Trabajo disponible en web abierta del Metaheuristics Network]. *PATAT Proceedings*.
- Russell, S. J., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4.^a ed.). Pearson.
- Russell, S. J., & Norvig, P. (2022). *Artificial Intelligence: A Modern Approach*, 4th US ed. Consultado el 13 de abril de 2026, desde <https://aima.cs.berkeley.edu/>
- Schaerf, A. (1999). A survey of automated timetabling. *Artificial Intelligence Review*, 13(2), 87-127.
- UniTime. (n.d.-a). *Course timetabling*. Consultado el 13 de abril de 2026, desde <https://help.unitime.org/course-timetabling>
- UniTime. (n.d.-b). *Rooms*. Consultado el 13 de abril de 2026, desde <https://help.unitime.org/rooms>